

機械学習とは何か・その主な手法

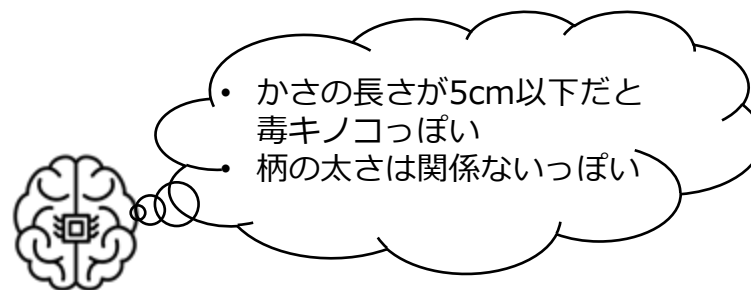
人間がルールや法則を指示するのではなく、データにある特徴やパターンをコンピュータが自動的に学習する技術。学習した結果、未知のデータに対してもデータの特徴やパターンから求めたい結果を予測できるようになる

コンピュータでデータを読み込む

例 毒キノコの特徴データ

				
かさの長さ	10cm	5cm	7cm	4cm
柄の太さ	1cm	2cm	5cm	2cm
毒キノコかどうか？	No	Yes	No	Yes

データから学習



学習データから特徴やパターンを自動で発見

予測

このキノコは食べられますか？



かさの長さ 8cm

柄の太さ 3cm

毒キノコ判別AI



これは毒キノコではないので食べられます！

他にもこんなところで機械学習が使われています

- スпамメールかどうかを自動で分類する
- 明日の気温を予測する
- 音声で文字を入力する
- ECサイトでおすすめの商品が表示される

機械学習の種類



機械学習には大きく分けて教師あり学習、教師なし学習、強化学習の3種類がある


教師あり学習

- 答えとなるデータが存在する
- 入力と答えの関係を学習することで入力から答えを予測する手法

キノコの特徴

			
入力データ			
かさの長さ	10cm	5cm	} 特徴量
柄の太さ	1cm	2cm	
毒キノコ?	No	Yes	
答えのデータ	学習時に答えを与える		

学習した結果




教師なし学習

- 答えとなるデータが存在しない
- 入力データのパターンから関係を見つけ出す手法

テストの結果


	Aさん	Bさん	Cさん	Dさん
入力データ				
数学	90	75	60	70
理科	80	60	50	90
社会	65	95	80	70
国語	80	70	90	70

学習した結果




強化学習


- 機械が選択した行動によって異なる報酬を与えることで、より多くの報酬を貰えるような行動を自動で見つけ出す手法



学習した結果



機械学習の中でも「ニューラルネットワーク」というモデルを使った手法(特に多層)のことを「ディープラーニング」と呼びます。機械学習の中で機械自身が試行錯誤を繰り返し、特徴量を調整しながら実行していく学習全般のことを指します



- これまで人間が設定したポイント(特徴量・報酬等)を機械が自動＝ディープラーニング
- 人間が各種ポイントを調整して学習を実行＝それ以外

空欄 [?] に当てはまる単語を考えてみましょう

[?]

- 機械が選択した行動によって異なる報酬を与えることで、より多くの報酬を貰えるような行動を自動で見つけ出す手法


[?]

- 答えとなるデータが存在し、入力と答えの関係を学習することで入力から答えを予測する手法

[?]

- 答えとなるデータが存在せず、入力データのパターンから関係を見つけ出す手法

機械学習



脳のシナプスを模した
様々な分析を自動的に行う
「ニューラルネットワーク」
の手法を活用した分析全般

空欄 [?] に当てはまる単語を考えてみましょう

[強化学習]


- 機械が選択した行動によって異なる報酬を与えることで、より多くの報酬を貰えるような行動を自動で見つけ出す手法

[教師あり学習]

- 答えとなるデータが存在し、入力と答えの関係を学習することで入力から答えを予測する手法

[教師なし学習]

- 答えとなるデータが存在せず、入力データのパターンから関係を見つけ出す手法






教師あり学習

教師あり学習は、説明変数（特徴量）から目的変数を予測するモデルを求める手法です。求め方として説明変数をモデルに入力し、モデルの出力が目的変数に近づくようにモデルを学習させます

「教師あり学習」の考え方




予測したい変数(目的変数)に近づくまで、
分析モデルを修正を繰り返す

教師あり学習、教師なし学習 教師あり学習の主な手法




教師あり学習は、**目的変数のデータの形式によって二つ（回帰、分類）に大別**されます。目的変数が自動車の価格等の連続値を取る場合は**回帰**と呼び、目的変数が「毒キノコ」か「安全なキノコ」といったカテゴリ（離散値）になる場合は**分類**と呼びます

回帰



分類



様々な回帰モデルの中でも、最も基本的なものが目的変数を複数の説明変数の重み付き和とバイアスで表現する線形回帰です。予測値と正解データの差分が少なくなるように重みを調整して展開していくことで、最適な予測モデルを作っていきます

線形回帰のモデル式

$$f(x) = \underbrace{w_1}_{\text{重み}} \underbrace{x_1}_{\text{説明変数}} + w_2 x_2 + w_3 x_3 + \cdots + w_n x_n + \underbrace{b}_{\text{バイアス}}$$

目的変数($f(x)$)を複数の説明変数(x)の重み(w)付き和とバイアス(b)で表現


|| ||
各説明変数が目的変数に すべての説明変数が0の場合
与える影響の大きさ 取る値。モデルの基準点

この式を活用して、
→ 計算結果と正解データの差分が少なくなるように重みを調整し、
最適な予測モデルを作っていく手法＝線形回帰

更に分類の手法として「決定木」というものも良く使われます。データの各属性の条件分岐を繰り返してクラス分けする方法です

決定木による分析イメージ(有毒なものの条件を分析)

凡例: ■ 有毒キノコ ● 無毒キノコ



※実際のプログラミングではクラス「DecisionTreeClassifier」を読み込、データ分析実施。上記は「DecisionTreeClassifier」の中で行われること


※決定木をいくつまで深ぼっていくかは決めることが可能

(参考) 分類木、回帰木

決定木には2つの種類があります。目的変数がカテゴリの場合は分類木、数値の場合は回帰木と呼びます

分類木


目的：
有毒かどうか
(カテゴリ)



・・・
高さと幅で
有毒どうか
考える

回帰木

目的：
鮮度がどの値
になるか？
(連続値)



・・・
高さと幅の
領域内のデータ
の平均値で
鮮度を予測

更に分類の手法として基本的な考え方の一つがロジスティック回帰です。これはあらゆる値を0～1の数値にするモデルで、YesやNoなどの質的データを予測します。前述の決定木で上手く予測がつかない場合等に活用されます

ロジスティック回帰のモデル式

$$f(x) = \frac{1}{1 + \exp(-(w_1x_1 + w_2x_2 + \dots + w_nx_n + b))}$$

線形回帰のモデル式

回答が0～1の間の数値になるようにできる式(シグモイド関数)
の中に線形回帰の式を入れることで、Yes or No等に分類が可能


※教科書では下記のように表されることもあります

$$\text{sigmoid}(w_1x_1 + w_2x_2 + w_3x_3 + \dots + w_nx_n + b)$$

※ロジスティックとは成長や減少などの変化過程を表すモデルのときに使われる用語

※まずはシグモイド関数=あらゆる値を0～1にする関数くらいの理解でOK

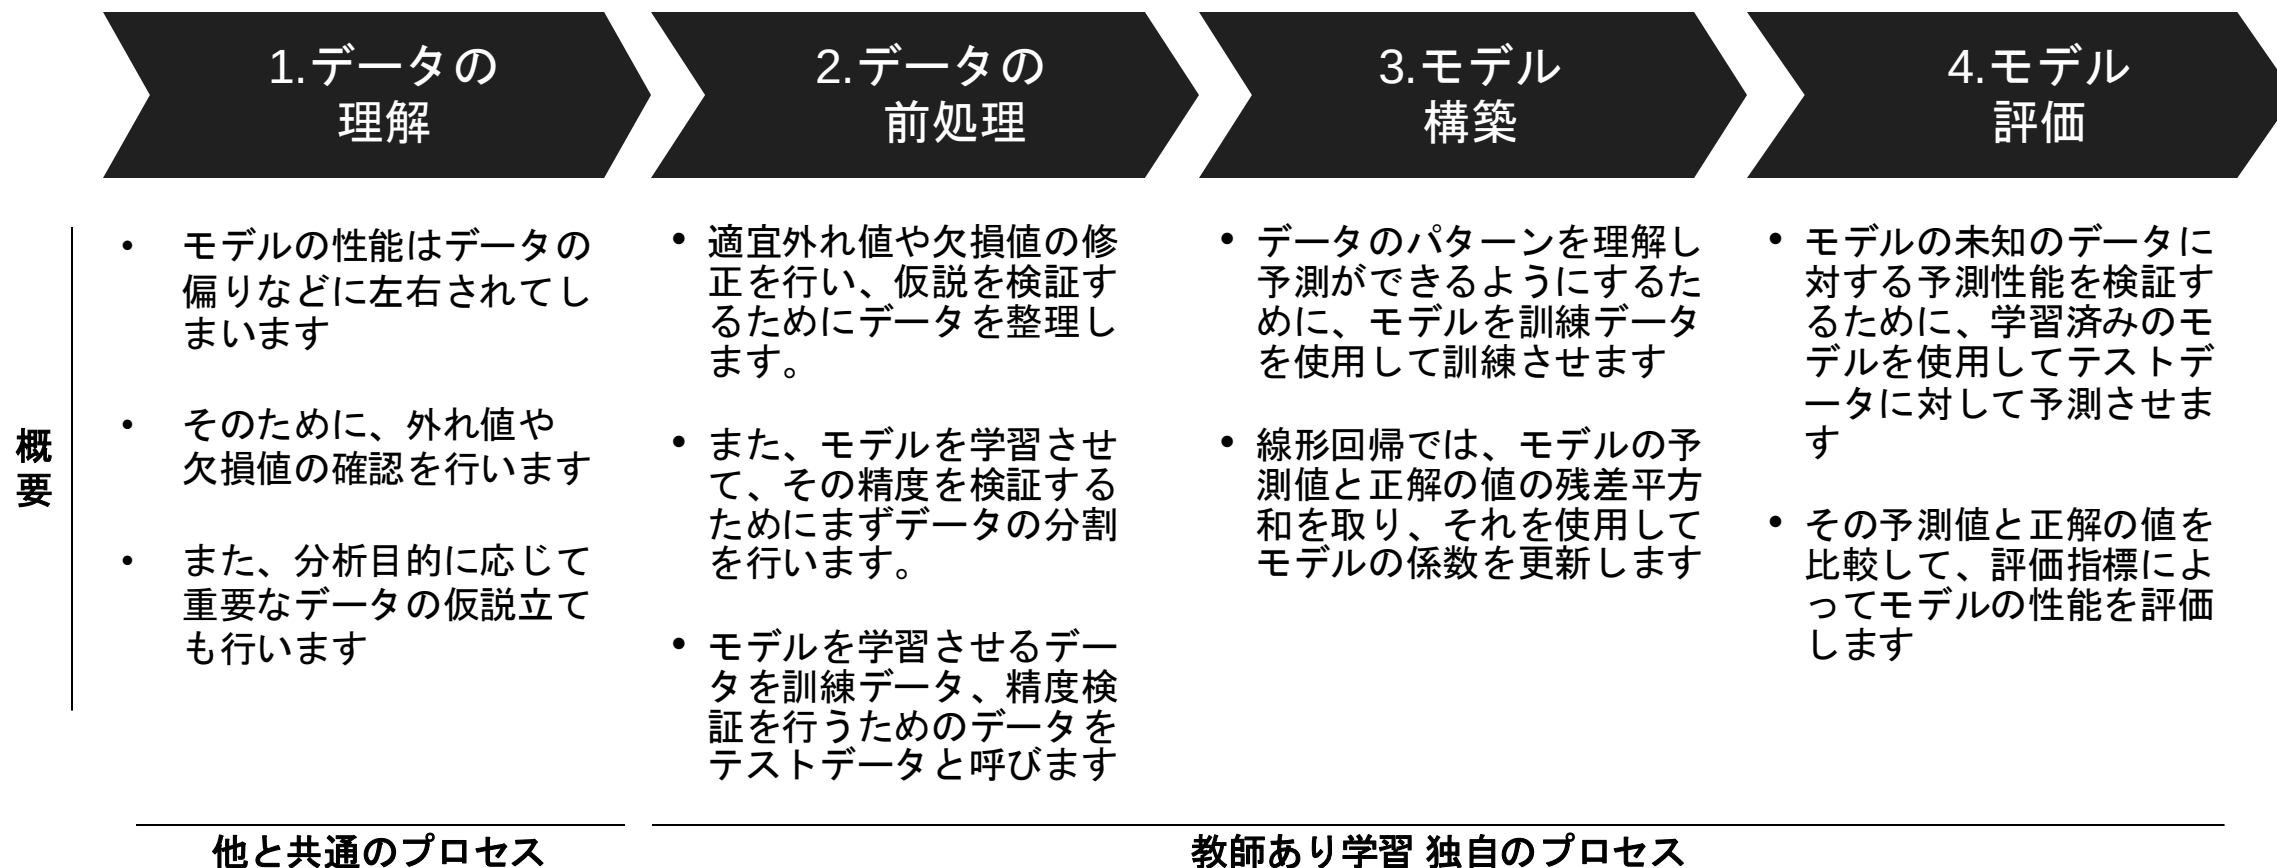
計算結果



0～1の数値にできれば、
正解のカテゴリになりえるところを「閾値」と設定して、Yes or Noの判断に使える

教師あり学習では、他の手法と大きな流れは一緒ですが、2. データの前処理～4.モデル評価にて他とは違ったプロセスで進めていきます

教師あり学習の分析プロセス



教師あり学習、教師なし学習 教師あり学習（回帰の分析事例）



例えば「回帰」の手法を使用した分析では、2.データの前処理や、3. モデル構築の際の重みづけを如何に調整するかが、良い結果を得るために特に重要になってきます

線形回帰の分析例

1.データの理解

X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
⋮	⋮	⋮	⋮

まずはデータを見ながら、
どの部分のデータを活用
できそうか確認する

2.データの 前処理

エンジン 大きさ (L)	車幅(m)	燃料の 種類	価格(ドル)
2.64	2.86	0	22112
3.15	4.04	1	43808
2.81	2.97	0	30306
2.64	3.42	0	29973
2.27	1.99	1	33074
2.47	2.43	1	35011
3.01	3.56	0	37612
3.34	3.75	0	40012
2.99	3.21	1	38701
2.55	2.70	1	32112
⋮	⋮	⋮	⋮

回帰分析に活用できそうと考
えるデータを取り出し、
欠損値・外れ値を修正する

3.モデル 構築

$$f(x) = w_1x_1 + w_2x_2 + w_3x_3 + b$$

線形回帰の各説明変数の重みづけ、
バイアスを調整の上でモデル構築

4.モデル 評価

モデルの 予測値	正解の値
価格(ドル)	価格(ドル)
39673	40012
39984	38701
30065	32112

予測結果と正解の値を比べながら、
より正解の値近づけるように、
各説明変数の重みづけを変えて
最適なモデルを構築していく
※モデルの最適さは前述の
平均二乗誤差を参考にする

教師あり学習、教師なし学習 教師あり学習（分類の分析事例）



同様に「決定木」の手法を使用した分析でも、2.データの前処理や、3. モデル構築の際の重みづけを如何に調整するかが、良い結果を得るために特に重要になってきます

決定木の分析例

1.データの理解

X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x

・
・
・

所有しているデータを整理、何か示唆を出せそうな部分がないか仮説立て

2.データの前処理


ID	高さ (cm)	幅 (cm)	毒か (Yes/No)
1	5	4	N
2	3	2	N
3	6	2	Y
4	2	1	N
5	5	1	Y
6	7	5	N

・
・
・

毒を特定できそうなデータをピックアップし、欠損値・外れ値を修正する

3.モデル構築

Decision Tree Classifier
にデータ読込



Decision Tree Classifierにデータ読込ませて、有毒かどうかを判定させる条件分岐を明確化し、モデル構築

4.モデル評価

予測結果

正解データ

必要に応じて再検討

構築されたモデルにより計算された予測結果と正解データを比べて、確度を高めるために必要に応じてモデルを再検討

教師あり学習に関して、空欄 [?] に当てはまる単語を考えてみましょう

[?]

- 目的変数を複数の説明変数の重み付き和とバイアスで表現する回帰手法

[?]

- あらゆる値を0～1の数値にするモデルで、YesやNoなどの質的データを予測する分類手法

[?]

- データの各属性の条件分岐を繰り返してクラス分けする手法
- 回帰、分類いずれの場合にも対応可能

教師あり学習に関して、空欄 [?] に当てはまる単語を考えてみましょう

[線形回帰]

- 目的変数を複数の説明変数の重み付き和とバイアスで表現する回帰手法

[ロジスティック回帰]

- あらゆる値を0～1の数値にするモデルで、YesやNoなどの質的データを予測する分類手法

[決定木]


- データの各属性の条件分岐を繰り返してクラス分けする手法
- 回帰、分類いずれの場合にも対応可能




教師なし学習

教師なし学習は、入力データに潜むパターンや示唆を見出す手法です。入力データ自体に注目しているため、正解となる目的変数を定められない場合に用います


分析対象のデータ



ゴールは不明確なものの、
データそのものに
傾向がないか分析



教師なし学習の結果




バラバラなデータで何の目的を達成できるものなのか不明
※特微量とは、予測に活用できる可能性があると考えた値


データの傾向が分かることで、示唆出しが行いやすくなる

主な教師なし学習の手法として、多数のデータをいくつかの類似するグループに分ける**クラスタリング**や、元の高次元のデータを情報を失わないようにして低次元のデータに圧縮する**主成分分析（PCA）**などの**次元圧縮**手法があります

クラスタリング



次元圧縮




教師あり学習、教師なし学習。 教師なし学習のプロセス



教師なし学習では、データサイエンスの流れと同様に、①データの理解、②データの前処理、③モデル構築、④モデル評価という4ステップを踏みます

教師なし学習の分析プロセス



クラスタリングでは1.データ理解に時間はかけずに、大まかに示唆が出そうな仮説を立て、3.モデル構築を繰り返すことで良いクラスタを出すことに重点を置きます

クラスタリングの分析例

1.データの理解

X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x

⋮
⋮
⋮
⋮

所有しているデータを整理、何か示唆を出せそうな部分がないか仮説立て

2.データの 前処理


店舗ごとの販売数

店舗	化粧品	衣類	食品
店舗A	15	30	40
店舗B	10	10	100
店舗C	90	15	25
店舗D	30	25	50
店舗E	100	10	15

⋮
⋮
⋮
⋮

例えば、店舗ごとの商品販売数をもとに示唆が得られないか、元のデータの欠損値・外れ値を調整しながらデータを整える


3.モデル構築



モデルの一つであるKmeans※を活用して、各データの離れている距離でのまとまりを計算・可視化

※中心となる点を定め、そこからの距離でまとめる手法

4.モデル評価



何度も試しながら示唆出せる良いクラスタ(まとまり)になるまで繰り返し→

たとえば、上記だと同じ商品が購入されやすい店舗ごとにグループ化し、在庫管理などに役立てる

次元圧縮の手法は、データの種類が多く、関係性を明らかにしづらいときに、シンプルに分析を進めるために活用されることが多いです

次元圧縮の分析例

1. データの理解

X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x
X x	X x	X x	X x

⋮
⋮
⋮
⋮

所有しているデータを整理、データ内容を確認しながら、何か示唆を出せそうな部分がないか仮説立て

2. データの前処理


index	数学	物理	化学	国語
0	86	74	78	74
1	90	86	82	70
2	84	90	86	79
3	88	94	92	82
4	80	82	95	84

⋮
⋮
⋮
⋮
⋮

複数の科目での学生の学力の傾向を知りたいと考え、いくつかの科目をピックアップ。欠損値・外れ値を整理

3. モデル構築

index	理系科目	国語
0	79	74
1	86	70
2	87	79
3	91	82
4	86	84



科目の特性や傾向をもとにまとめられる方向性を考え、集約(固有ベクトルと固有値の発見・写影の実施)する

4. モデル評価

index	理系科目	国語
0	79 ↔ 74	
1	86 ↔ 70	
2	87 ↔ 79	
3	91 ↔ 82	
4	86 ↔ 84	

⋮
⋮
⋮

教師なし学習に関して、空欄 [?] に当てはまる単語を考えてみましょう

[?]

- 多数のデータをいくつかの類似するグループに分ける手法

[?]

- 元の高次元のデータを情報を失わないようにして低次元の次元に圧縮する手法

教師なし学習に関して、空欄[?]に当てはまる単語を考えてみましょう

[クラスタリング]

- 多数のデータをいくつかの類似するグループに分ける手法

[次元圧縮]

- 元の高次元のデータを情報を失わないようにして低次元の次元に圧縮する手法

教師あり学習、教師なし学習の応用（LLM）

大規模言語モデル(LLM)




近年流行しているGPT-4やClaudeといった**大規模言語モデル(LLM)**の学習では、**教師あり学習、教師なし学習**の両方の概念を取り入れた**自己教師あり学習**を行います

擬似ラベル付け
(教師なし学習)

擬似ラベルを正解データとした学習
(教師あり学習)

モデル提供
(LLM)



この活動を自動的に行うため、「**自己教師あり学習**」と呼ばれる

大規模言語モデル(LLM)の学習手法

LLMでは前述のように自己教師あり学習により構築されますが、主に「Next Token Prediction (次の単語の生成確率を予測する手法)」によって学習が進められています。これにより、一部の入力情報から次の言葉を予測できるようになります

擬似ラベル付け
(教師なし学習)



正解ラベルがないデータ
を分類しつつ、
擬似ラベルを作成

擬似ラベルを正解データとした学習
(教師あり学習)



擬似ラベルを正解としてモデルづくり

モデル提供
(LLM)



LLMとして提供

事例：「吾輩は猫である」の文章予測LLM※理解のため簡易化

- 「吾輩は猫である」との文章を入力
- 「吾輩」、「は」、「猫」、「である」というように要素分け
- それぞれの要素や繋ぎ合わせたフレーズを正解ラベルとして擬似ラベル化



- 大量の文章データを活用しながら、擬似ラベルが正解となる説明変数・重みづけの設定(モデルづくり)
- 予測結果と擬似ラベル(正解データ)との比較により、モデルを自動改善



- 「吾輩」と入力があれば「は」が出てきて、「吾輩は猫」を入力とすれば、「吾輩は猫である」が出力されるLLMが構築される(正確には出力される確率が高いLLMが構築される)
- これを他関連データでも行くと、「夏目漱石の主著は？」といった入力にも対応できるようになる

この一連の学習の流れが「Next Token Prediction」と呼ばれる

空欄 [?] に当てはまる単語を考えてみましょう

擬似ラベル付け
(教師なし学習)

擬似ラベルを正解データとした学習
(教師あり学習)

モデル提供
(LLM)



LLMは、教師あり学習と教師なし学習の
概念を取り入れた [?] によって学習を行う

空欄[?]に当てはまる単語を考えてみましょう

擬似ラベル付け
(教師なし学習)

擬似ラベルを正解データとした学習
(教師あり学習)

モデル提供
(LLM)



LLMは、教師あり学習と教師なし学習の概念を取り入れた
[自己教師あり学習] によって学習を行う