

3. 活用するために必要な統計の知識

データサイエンスのどこで統計の知識を用いるのか？

データサイエンスの流れの一番始め、「データの理解」の工程でデータが持つ意味合いや特徴を理解するために統計の知識が必要となります

1. データ
の理解

2. データ
の前処理

3. モデル
構築

4. モデル
評価

目的
達成

統計の知識を用いながら
データを解釈する

ではここから、

「学生20人の英語と数学のテストの結果を見たところ、2科目とも平均点は62点だった」

というデータを例に見ていきましょう

元となるデータ（学生別のテストの点数）

	英語	数学
学生1	65	85
学生2	80	55
学生3	35	40
学生4	55	90
学生5	65	35
学生6	80	40
学生7	55	50
学生8	65	40
学生9	50	95
学生10	85	40

	英語	数学
学生11	55	90
学生12	55	45
学生13	70	85
学生14	50	45
学生15	80	40
学生16	70	85
学生17	65	50
学生18	80	55
学生19	65	100
学生20	15	75


英語の平均点：62点
数学の平均点：62点

「データがどの範囲にどれだけ集まっているか」を視覚的に見るためのグラフです。データをいくつかの区間に分け、その区間に該当するデータの数（頻度）を棒の高さで示すことで、データの全体的な傾向や偏りを確認することができます

データについての疑問


「学生20人の英語と数学のテストの結果を見たところ、2科目とも平均点は62点だった」
ということから、英語と数学は同じくらいの難しさだったと言えるのだろうか？

ヒストグラムで表すと※データサイエンスではまずヒストグラムでデータの分布を確認することが一般的



階級

横軸：階級（データを一定の幅で区切ったもの 上の場合は10点刻み）



度数

縦軸：度数（各階級に含まれるデータの個数 上の場合は人数）

平均点は同じでも
点数の分布が違いそうだ

平均値 (mean) ・ 中央値 (median)

データを見るときには平均値(すべてのデータの合計をデータの個数で割った値)や中央値(データを小さい順に並べたときの真ん中の値)で確認をすることも多いです

データについての疑問

データの値の特徴を確認するためには、例えばどうすればよいか？

テストの点数を小さい順に並び替えて、平均値と中央値を見ていると

平均値と中央値
どちらが大きいかは
データによる

英語

15 35 50 50 55 55 55 55 65 65 65 65 65 70 70 80 80 80 80 85

小さい方から10人分

大きい方から10人分


中央値※ = 65

点数の合計 人数の合計

1240

20

平均値 = 62
(1240 ÷ 20)



数学

35 40 40 40 40 40 45 45 50 50 55 55 75 85 85 85 90 90 95 100

小さい方から10人分


大きい方から10人分

中央値※ = 52.5

1240

20

平均値 = 62
(1240 ÷ 20)



※データが奇数個の場合の中央値は小さい順に並び替えたときのちょうど真ん中の値

※偶数個の場合の中央値は真ん中に位置する左右2つのデータを足して2で割った値(上記2つ)

平均値を計算式で表すと、データの合計÷データ個数ということになる。また、コードとしては下記のようにNumpyを読み込んでプログラミングしていく

平均値の求め方

- ①各データを足し合わせる
 - ②①をデータの個数で割る
- 答えが「平均値」

<計算式> ※式については、まずはこのようなものと眺めるだけでよい

$$\text{平均値} = \bar{x} = \frac{\text{データの合計}}{\text{データの個数}} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

コードとして記載した例

こちらでもコード演習時に実際に手を動かしながら定着させていけばOK

```
In [1]: import numpy as np  
        np.mean([0, 2, 4, 6, 8])
```

```
Out [1]: 4.0  
         平均値  
         (上記を足し合わせて、データ個数で割った数字)
```


※コードで書ければ、計算式を覚える必要はなく、概念の意味・活用する理由が分かっているだけで問題ない

データの分布を視覚的に把握するための手法として「箱ひげ図」があります。データの最小値、最大値、中央値を一目で把握することができ、傾向の違いを確認できます

データについての疑問

英語と数学の点数の分布をうまく表現する方法は他にないだろうか？

箱ひげ図で表した科目別のテストの点数



■ 箱ひげを理解するため必要事項

- 箱は第1四分位数から第3四分位数までを表し、これを四分位範囲と呼ぶ。箱の中にはデータのうち1/2の個数が含まれる
- ひげは通常最小値、最大値まで伸びる。ひげの長さは四分位範囲の1.5倍を最大とし、それより外側の値を外れ値と呼ぶ。ひげが長いほどデータの広がりが大きい

データのばらつき具合を確認したいときに活用するのが「分散」です。数値の大きさにより、平均値からどの程度差分があるデータなのか等を確認できます

データについての疑問

グラフで見ると数学の方が点数がばらついていそうだ。このばらつきを表現する方法はあるのだろうか？

先ほどのテストの点数の分散を計算すると

数学のテストの方が分散が大きい＝ばらつきが大きい


英語のテストの分散：285.3

数学のテストの分散：**524.7**

例えば、各テストの点数を計算すると、数学の方がテストの平均値から遠い点数が多い(分散している)


※計算方法は次ページ

分散のイメージ



分散が小さい

- 平均値の周辺にデータが固まっている
- 狭い範囲にデータが集まっている
- ヒストグラムの階級(すそ野)が狭い



分散が大きい

- 平均値から遠くにデータが散らばっている
- 広い範囲にデータが散らばっている
- ヒストグラムの階級(すそ野)が広い

分散の求め方と、Pythonを使ったコードで表すと以下ようになります

分散の求め方

- ①平均値を算出
 - ②各データと平均値との差を算出(平均値との差 = 偏差)
 - ③②の各データをデータを2乗(値がマイナスになるのを防ぐため)
 - ④③を足し合わせる
 - ⑤データの個数で割る
- 答えが「分散」(データのばらつき具合)

<計算式> ※式については、まずはこのようなものと眺めるだけでよい

$$\text{分散} = \sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

x_i は各データ、 $\bar{x}$ は平均値、 n はデータの個数を表す
各データと平均値の差(偏差)を二乗して、
それをデータの数だけ全部足し合わせて、
データの個数で割ったもの

<具体例> ※上記に基づいて計算

データ $x=[60,70,80,90,100]$

- ①平均 $(60+70+80+90+100)\div 5=80$
- ② $(60-80)=-20$ 、 $(70-80)=-10$ 、 $(80-80)=0$ 、 $(90-80)=10$
 $(100-80)=20$
- ③それぞれ2乗で400、100、0、100、400
- ④足し合わせて1000
- ⑤ $1000\div 5=200$ = 「分散」

コードとして記載した例

```
In [1]: import numpy as np  
        np.mean([0, 2, 4, 6, 8])
```

Out [1]: 4.0 (平均値)

```
In [2]: np.var([0, 2, 4, 6, 8])
```

Out [2]: 8.0 (分散)

```
In [3]: np.var([0, 2, 4, 8, 11])
```

Out [3]: 16.0 (分散)

データのばらつきが
大きくなるほど、
分散の値は大きくなる

※コードで書ければ、計算式を覚える必要はなく、概念の意味・活用する理由が
分かっている問題ない

分散は元データの単位が二乗されており直感的に値の意味あいを把握しにくいいため、分散の平方根を取り単位を元のデータと揃えた**標準偏差**を用いることも多いです



先ほどのテストの点数の標準偏差を計算すると

英語のテストの標準偏差：16.9

数学のテストの標準偏差：22.9

標準偏差にすると、より扱いやすい数値となる。元のデータに戻したため、単位も元データと同様の「点数」

標準偏差とデータ分布の関係



平均と標準偏差の差が1つ分くらいまでならズレが少ないもの、2つ分以上だとデータはズレが大きいもの(特殊)とされる

標準偏差の求め方と、Pythonを使ったコードで表すと以下のようになります

標準偏差の求め方

- ①「分散」を求める
 - ②「分散」の平方根を取る
- 答えが「標準偏差」

<計算式> ※式については、まずはこのようなものと眺めるだけでよい

$$\text{標準偏差} = \sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}}$$

x_i は各データ、 $\bar{x}$ は平均値、 n はデータの個数を表す

コードとして記載した例

```
In [3]: np.var([0, 2, 4, 8, 11])
```

```
Out [3]: 16.0 (分散)
```

```
In [4]: np.std([0, 2, 4, 8, 11])
```

```
Out [4]: 4.0 (標準偏差)
```

分散の平方根を取った
ものが標準偏差

※コードで書ければ、計算式を覚える必要はなく、概念の意味・活用する理由が
分かっているだけで問題ない

様々なデータを同じ基準で比較するための手法であり、標準化では「各データが平均からどれくらい離れているか」を、標準偏差の単位で測ることができます

データについての疑問

英語の85点と数学の85点は両方同じくらいできたと言っているのだろうか？

標準化の方法（参考）

①各データー平均値

各データが平均からどの程度の差分かを明確化
(各データのバラつきを明確化)

②①を標準偏差で割る

各データが標準偏差と比べて、どの程度違いがあるかを明確化
(バラつきの度合いがどの程度かを明確化)

<計算式> ※式については、まずはこのようなものと眺めるだけでよい
データを標準化した値をZとすると

$$Z = \frac{x_i - \bar{x}}{\sigma} \quad \text{これをZスコアと呼ばれる}$$

x_i は各データ、 $\bar{x}$ は平均値、 σ は標準偏差を表す

このように計算することで、異なるデータでも
同じ指標で各データのばらつきを比較することが
できるようになる(例えば偏差値)
そのため、この手法を各データの「標準化」と呼んでいる

標準化の例(偏差値)

- 試験の成績を表す際におなじみの偏差値は平均を50と考え、標準偏差を10と置いた上で、各データがどの程度平均から離れているかを見ている。離れている度合いを確認するために各データの標準化した値(Zスコア)を掛けて考える
- そのため、計算式は偏差値 = $50 + 10 \times Z$ で求める

取りあげているデータの偏差値

	英語		数学	
	点数	偏差値	点数	偏差値
学生1	65	52	85	61
学生2	80	61	55	47
学生3	35	33	40	40
学生4	55	46	90	63
学生5	65	52	35	38
学生6	80	61	40	40
学生7	55	46	50	44
学生8	65	52	40	40
学生9	50	43	95	65
学生10	85	64	40	40

	英語		数学	
	点数	偏差値	点数	偏差値
学生11	55	46	90	63
学生12	55	46	45	42
学生13	70	55	85	61
学生14	50	43	45	42
学生15	80	61	40	40
学生16	70	55	85	61
学生17	65	52	50	44
学生18	80	61	55	47
学生19	65	52	100	67
学生20	15	21	75	56


同じ85点でも英語なら偏差値64、数学なら偏差値61

2つのデータの間を視覚的に表すグラフを「散布図」といい、点の並び方で2つのデータが関連しているのか無関係なのかを判断することができます



データについての疑問

英語の点数が高い人は数学の点数も高いと言っているだろうか？

散布図で表すと



もし2つのデータが関連しているときは散布図はどのようなのか？



「一方の値が大きくなるにつれ、もう一方の値も大きくなる」
あるいは
「一方の値が大きくなるにつれ、もう一方の値が小さくなる」
という形の散布図になる


相関係数はデータ間の関連性の強弱を確認したいときに用いる手法です。相関があるからといって因果関係があるとは限らないこともポイントです

先ほどのテストの点数の相関係数を計算すると

相関係数 = -0.21

※求め方は次ページ

相関係数からも
ほとんど相関がないと
言えそうだ



確かに先ほどの散布図を
見ても、右上がりの傾向
も、右下がりの傾向も見
られない

相関係数の値の意味

正の相関 ($0 < \text{相関係数} \leq 1$)

- 正の相関がある場合、2つのデータの値が同じ方向に動くことを意味します。明確な基準はありませんが、目安として0.7以上あると「強い正の相関がある」と言います

負の相関 ($-1 \leq \text{相関係数} < 0$)

- 負の相関がある場合、1つのデータの値が増えるともう1つのデータの値が減る傾向があることを示します。明確な基準はありませんが、目安として-0.7以下だと「強い負の相関がある」と言います

相関が弱い (0に近い)

- 相関係数が0に近いほど、2つのデータの関係は弱くなり、0ならまったく関係がないことを意味します。明確な基準はありませんが、目安として-0.2から+0.2の間だと「ほとんど相関がない」と言います(左記は、このイメージ)

※ただし、相関が強くても因果関係があるとは限らない

相関係数の求め方と、Pythonを使ったコードで表すと以下のようにになります。求め方が複雑になるため、まずは概念と活用理由を理解するだけでも問題ありません

相関係数の求め方

- ①2つの軸のデータ(X、Yとする)のそれぞれの「平均値」を算出
- ②X、Yの各データと平均値の差を算出
ここまでは、それぞれのデータの平均値との差を確認
- ③XとYの各データを掛け算する
掛け算した値の大小でXとYの相関性の強さ(共分散という)を見る
- ④XとYの掛け算したものを足し合わせる
全体での値の大きさを確認する
- ⑤XとYの標準偏差を出して、各標準偏差を掛ける
- ⑥④を⑤で割る
④のままだと値の大小で直感的にしか相関性を見れないため、共分散と同様に掛け算した標準偏差で割ることで-1~1の間の数字に変えることができ、相関性を分かりやすくなる
→答えが相関係数

<計算式> ※式については、まずはこのようなものと眺めるだけでよい

$$\text{相関係数} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}}$$

x_i, y_i は各データ、 $\bar{x}, \bar{y}$ は平均値、 n はデータの個数を表す
共分散を標準偏差で割ったものと考えてる

コードとして記載した例

```
In [1]: import numpy as np
        x = [1, 2, 3, 4, 5]
        y = [4, 7, 9, 10, 11]
        np.corrcoef(x, y)[0, 1]
```

Out [1]: 0.9686648999069225 (強い正の相関)


```
In [2]: x = [1, 2, 3, 4, 5]
        y = [11, 10, 10, 7, 3]
        np.corrcoef(x, y)[0, 1]
```

Out [2]: -0.9183996645933804 (強い負の相関)


※コードで書ければ、計算式を覚える必要はなく、概念の意味・活用する理由が分かっているだけで問題ない

- 次のグラフは何という名前でしょうか？


①



②




③




- 次のグラフは何という名前でしょうか？

①




散布図

②



箱ひげ図

③



ヒストグラム

- Aというデータの集まりと、Bというデータの集まりがあるとして
次のことが知りたいとき、何を求めるとよいでしょうか？

1. AとBには関係があるのか？

2. AとBのどちらがデータがばらついているのか？

3. Aの中で大きい方から数えても、小さい方から数えても同じ位置にあるデータの値は？

- Aというデータの集まりと、Bというデータの集まりがあるとして
次のことが知りたいとき、何を求めるとよいでしょうか？

1. AとBには関係があるのか？

相関係数

2. AとBのどちらがデータがばらついているのか？

分散 もしくは 標準偏差

3. Aの中で大きい方から数えても、小さい方から数えても同じ位置にあるデータの値は？

中央値